



Machine Learning Team Project

Team name : 러닝머신

- 20211513 김동준
- 20211546 이채현 (조장)
- 20212996 허준범



01 과제 분석

02 성능 평가 지표

03 배경 및 전경색 분류 문제

04 숫자 분류 모델 후보

05 전처리

06 모델 선정

07 데이터 증강

08 그리드 탐색

09 결과

과제 분석

1. 프로젝트 목표

- 목표: Colored MNIST 데이터셋을 활용한 고성능 분류 모델 구축
- 도전 과제: 색상과 형태 정보를 동시에 고려해야 하는 복합 문제

2. 데이터셋 구축 및 특성

- 생성 과정: Original MNIST (28x28x1) 기반 => Threshold로 형태 추출 => RGB 색상 정보 주입
- 구조적 특징: 28 x 28 x 3 uint8



평가 지표

- 정확도 (Accuracy)

선정 근거

- 0~9의 정답이 확실한 문제
- 0~9 클래스가 고르게 분포되어 있어 클래스 불균형 문제가 없음

배제 지표

- 데이터가 균형 잡혀있고 순수한 정답률 파악이 중요하므로, Precision / Recall / F1 Score은 평가에서 제외

배경 및 전경색 분류 문제

배경/전경색 추출 방법론

Background color, Foreground color 구분을 위한 두 가지 주요 접근 방식을 구성.

접근 1: 머신러닝 분류 모델

접근 2: 색상 팔레트 기반 알고리즘 (선정)

- 이미지 픽셀을 팔레트 내 가장 가까운 거리'의 색상으로 매핑.
- 매핑된 색상의 빈도수를 집계하여, 가장 빈도가 높은 색을 배경색으로, 두 번째로 높은 색을 글자색으로 판별.

정확도 종합	OVO(SVC)	알고리즘
전경색	0.9946	1.0000
배경색	1.0000	1.0000



숫자 분류 모델 후보

- **KNN (K-Nearest Neighbors)**
 - 분류의 가장 기초적인 모델 => '기준점'
- **OvO – Linear Regression**
 - 대표적 선형 모델 => '선형 vs 비선형'
- **OvO – SVC**
 - 대표적 비선형 모델 => '선형 vs 비선형'
- **Random Forest**
 - ensemble 기법 도입

전처리

흑백 변환

- 원본 데이터(Colored MNIST)의 문제: 색상 정보는 숫자 분류의 본질(형태)과 무관한 노이즈로 작용.
- 효과 : 색상 정보를 제거하고 형태적 특징(Shape)에 집중.



전처리

성능 비교 대상

- 원본 (RGB): 전처리 없는 초기 데이터.
- 흑백 (배경 흑): 배경을 검은색(0), 숫자를 밝게 처리.
- 흑백 (배경 백): 배경을 흰색(255), 숫자를 어둡게 처리.



전처리

전처리 효과

- 모든 모델에서 성능 향상을 관측
- 배경이 흑색인 경우가 더 높은 성능을 보임

모델	원본	흑백 (배경 흑)	흑백 (배경 백)
OVO (SVC)	0.8279	0.9808	0.9809
OVO (LR)	0.1757	0.9501	0.1149
KNN	0.8742	0.9631	0.9635
Random Forest	0.9260	0.9779	0.9774

OvO (SVC) 선정

- 가장 높은 성능(정확도)
- GPU 환경에 적합(높은 병렬화)

모델	Accuracy
KNN	0.9631
Random Forest	0.9779
OvO (LR)	0.9499
OvO (SVC)	0.9808


데이터 증강

혼동 행렬 분석

- SVC-OVO 모델의 예측 실패 사례를 시각화

주요 오분류

- 형태학적 유사성이 높은 숫자 쌍에서 오류 집중
- Top 3 오분류 (양방향)
 - $4 \Leftrightarrow 9 = 30$ 건
 - $3 \Leftrightarrow 8 = 19$ 건
 - $9 \Leftrightarrow 7 = 15$ 건



데이터 증강

문제 인식

- 손글씨 데이터의 특성상 육안으로도 식별 불가능한 데이터 다수 존재
- 모든 데이터를 완벽하게 분류하는 'Human-above' 성능 달성은 현실적으로 불가능

전략 수립

- 목표 재설정: 지나치게 지저분한 글씨의 오류는 인정하되, 명확한 글자의 인식률을 극대화
- 'Human-like' 지향: 사람이 인식할 수 있는 수준의 깔끔한 글자에 대한 정답률 향상에 집중


데이터 증강

폰트 증강 도입

- 데이터 추가: 15건 이상 혼동(Confusion)이 발생한 3, 4, 7, 8, 9 대상
- MaruBuri 폰트 활용, 각 6,000장 이미지 추가 학습

기대 효과

- 글자 고유의 구조적 특징에 집중
- 클래스 내 일반화 새로운 글자체 대응




주요 성과

- 유사 형태의 구조적 특징 학습
- 주요 개선
(9 / 3 : +5), (4 / 9 : +4), (5 / 3 : +4), (7 / 4 : +3), (3 / 8 : +2) => 혼동이 잦았던 숫자 쌍의 오류 감소

종합 정량 평가

- (+35 / -15 / total: +20)
- Accuracy
0.9808 => 0.9825 / +0.17%p



데이터 증강

오류 분석

- 폰트 증강이후에도 여전히 발생하는 오류 데이터 검수
- 다수의 오분류 이미지가 기울어진 형태

원인 분석

- 손글씨는 고유한 방향성 편향 존재

클래스별 기울기 특징

- 좌측 기울임: 숫자 3
- 우측 기울임: 숫자 7, 8, 9, 4




데이터 증강

회전 증강 도입

- 데이터 추가: 폰트 증강 후에도 15건 이상 혼동이 발생한 클래스 (3, 4, 7, 8, 9)
- 무작위 $-5^{\circ} \sim +5^{\circ}$ 기울임 데이터 각 클래스당 6,000장 추가 생성

기대 효과

- 글자 고유의 구조적 특징에 집중
- 클래스 내 일반화 '자연스럽게 쓴 기울어진 글씨' 대응




주요 성과

- 유사 형태의 구조적 특징 학습
- 주요 개선 (실제 / 예측)
 $(8 / 5 : +4)$, $(3 / 5 : +2)$, $(3 / 8 : +2)$, $(4 / 9 : +2)$, $(9 / 5 : +2)$ => 혼동이 잦았던 숫자 쌍의 오류 감소

종합 정량 평가

- $(+35 / -10 / \text{total: } +25)$
- Accuracy
 $0.9825 \Rightarrow 0.9846 / +0.21\%p$




데이터 증강

주요 성과

- 유사 형태의 구조적 특징 학습
- 주요 개선 (실제 / 예측)
 $(4 / 9 : +6)$, $(7 / 4 : +5)$, $(8 / 5 : +5)$, $(9 / 3 : +4)$, $(3 / 8 : +4)$ => 혼동이 잦았던 숫자 쌍의 오류 감소

종합 정량 평가

- $(+58 / -13 / \text{total: } +45)$
- Accuracy
 $0.9825 \Rightarrow 0.9846 / +0.21\%p$



데이터 증강

정확도 비교

Step	단계별 손익	Accuracy	성능 증가분
증강 이전	-	0.9808	-
Font 증강	-15 / 35	0.9825	0.17%p
Font 증강 + Tilt 증강	-10 / 35	0.9846	0.21%p
이전 vs 최종 증강	-13 / 58	0.9846	0.38%p
*참고: Test 조건 : Colored MNIST 를 미리 전처리 기법을 수행하여 저장, 흑백 이미지 60k 중 random selected 80%를 train set, 나머지를 validation set로 시행			

그리드 탐색

- 전수 탐색: 후보 집합의 모든 조합을 순차적으로 검증하여 최적해 보장.
- 분석 용이성: 특정 파라미터가 성능에 미치는 영향을 명확히 비교·분석 가능.

연산 효율화

- 적은양의 탐색용 데이터셋 (학습 데이터의 랜덤 50%) 생성

SVC 핵심 파라미터

- 커널 함수: RBF (Radial Basis Function) 기준 최적화.
- 정규화 계수 (C): 오분류 허용 정도 조절
- 커널 파라미터 (γ): 데이터 영향 범위 조절

목적

- 최적 파라미터 근방의 빠른 탐색

최종 도출 결과

- C=10
- γ = 'scale'

1차 그리드 탐색 범위	
C	1e-2, 1e-1, 1(초기값), 1e1, 1e2
γ	1e-9, 1e-8, 1e-7, *scale(초기값), 1e-6, 1e-5

그리드 탐색

목적

- 최적 파라미터의 정밀 탐색

전략

- Target: 1차 탐색 결과 ($C=10$, $\gamma='scale'$) 인근의 세부 구간 집중 공략.
- 과적합 방지 : 5 fold cross validation

최종 도출 결과

- $C=6$
- $\gamma= 3e-7$

2차 그리드 탐색 범위	
C	2, 4, 6, 8, 10, 12, 14, 16, 18
γ	1e-8, 3e-8, 5e-8, 7e-8, 9e-8, 1e-7, 3e-7, 5e-7, 7e-7, 9e-7

일반화된 신뢰성 확보

- 교차 검증을 통해 최적 파라미터를 검증.


최종 성능 평가

- 탐색된 파라미터를 바탕으로 모델 재학습

모델	Accuracy	성능 증가분
증강 기법 적용 이후	0.9846	-
최종 모델	0.9882	0.36%p

결과

Step	Accuracy	성능 증가분	비고
Base_Colored	0.8279	–	최초 실행
Base_BW	0.9808	15.29%p	흑백 전처리 도입
Font 증강	0.9825	0.17%p	증강 도입
Tilt 증강	0.9846	0.21%p	증강 도입
Hyper parameter tuned	0.9882	0.36%p	Grid Search 수행 (최종 모델)
※ 모든 시행은 같은 validation set를 통해 Accuracy 측정			



최종 구조 설명

- 색상 분류(팔레트 기반 매칭 알고리즘)과 숫자 분류(머신러닝 모델)를 유기적으로 연결,
컬러 이미지가 입력되었을 때 최종 결과(숫자, 전경색, 배경색)를 한 번에 도출하는 단일 통합 구조를 구축.

code)

```
bw_images, predicted_fg, predicted_bg = predict_colors(test_images)
predicted_digit = predict_digit(bw_images)
```

diagram)

(좌측 이미지)

Machine Learning Team Project
최종발표

The End.

Team name : 러닝머신

- 20211513 김동준
- 20211546 이채현 (조장)
- 20212996 허준범

